

基于 REFIL 的全局信息处理与规模外推

中文研究设计稿 · 双色架构与训练细化版 · 2026 年 9 月 15 日

本文提出三个可独立验证的研究方案，分别研究数量变化引起的表示偏移、全局信息的迭代加工，以及暂定决策参与的循环协调。本版重点细化方案一、二，统一采用保留 REFIL 原路径、并行增加全局分支的实现。方案三保留为决策反馈机制的解释；它需要额外的执行信息条件，不与前两种方案直接等同。

三种方案目前均为研究假设，尚未完成实现与性能验证。已有论文提供结构与训练依据，不代表已经证明这些改动能够提升当前任务的规模外推能力。本次附带的两份 PDF 实际为 SARC 正文与技术补充，以下关于 REFIL 的分析依据其公开论文和官方代码。

1 REFIL 原结构与统一接入方式

1.1 图中颜色的含义

图 1、图 2 使用相同的两类组件颜色。**蓝色表示沿用 REFIL 的组件，橙色表示本研究新增的组件。**灰色仅用于输入、连线或说明。蓝色不表示参数冻结：两类组件都通过同一强化学习目标端到端训练。

蓝色：REFIL 原有部分	橙色：本研究新增部分
逐实体编码 fc1 与 ReLU	红方、蓝方和目标数量的有界编码
原实体注意力、fc2 与 ReLU	方案一的数量校正全局注意力
时间 GRU 与动作效用头 fc3	方案二的共享循环全局模块与跨轮读取
Mixer、状态条件超网络	将全局上下文接入原网络的残差融合
随机组内／组外辅助分支及 TD 训练机制	新增分支在各辅助掩码下的相应计算

原 REFIL 并不包含预先分开的局部、全局双分支。作者实现依次执行逐实体编码、实体注意力、fc2、时间 GRU 和动作效用头。本版将这一路径整体保留，把新增全局处理明确画成并行分支。[REFIL 个体网络实现](#)

1.2 执行信息与数量定义

研究任务是在较小规模上训练共享策略，冻结后部署到较大规模。新增全局分支读取的是**执行时已经允许获得的全场实体态势**，不读取只供训练 Mixer 使用的特权状态。若原基线没有这些观测，必须提供具有相同执行信息的 REFIL 对照。

设实体集合为 $X_t = \{(x_j, c_j)\}_{j=1}^{N_t}$ ， $c_j \in \{R, B, T\}$ 。位置、速度等使用原始实体特征，不引入手工威胁指标或目标分配规则。对接收方 i 和训练分支 b ，允许读取的实体集合记为 $S_{i,t}^b$ ，其中 $b \in \{\text{main}, \text{in}, \text{out}\}$ 。数量统一定义为

$$n_{i,c,t}^b = \sum_{j \in S_{i,t}^b} \mathbf{1}[c_j = c].$$

主分支能够看到全场时，这就是全场红方、蓝方和目标数量；辅助分支则必须重新计算其允许集合内的数量。后文省略 i, t, b 下标，不表示可以跨掩码共享完整信息。

正数量沿用前面讨论的编码

$$b(n) = \left(\frac{n-1}{n+1} \right)^2, \quad n \geq 1.$$

为区分零个与一个实体，定义 $\eta_c = \mathbf{1}[n_c > 0]$, $\bar{b}_c = \eta_c b(\max(n_c, 1))$ ，再令

$$z_n = E_n([\bar{b}_R, \bar{b}_B, \bar{b}_T, \eta_R, \eta_B, \eta_T]).$$

存在标记完全由数量决定，没有增加额外态势指标。有界编码不能自动保证外推： $b(10) \approx 0.669$, $b(50) \approx 0.923$ ，后者仍超出仅训练到 10 时的输入范围。

1.3 两种方案共用的融合接口

记原路径中 fc2 与 ReLU 的输出为 $\ell_{i,t}$ 。原 REFIL 直接将其送入 GRU。本版在这一位置加入固定宽度的残差融合：

$$\begin{aligned} \tilde{\ell}_{i,t} &= \ell_{i,t} + W_u u_{i,t} + W_n z_n, \\ h_{i,t} &= \text{GRU}(\tilde{\ell}_{i,t}, h_{i,t-1}), \quad \mathbf{Q}_i = W_Q h_{i,t} + b_Q. \end{aligned}$$

W_u, W_n 是新增投影，使新增信息与原 GRU 输入维度一致。原实体注意力、fc2、GRU 和动作头均保留原结构。方案一、二只改变 u_i 的构造方式，不同时改变融合方式、动作空间或奖励。

两种方案均不需要交换其他智能体的隐藏状态或暂定动作。全局槽可以仅由公共实体态势计算，每个智能体再用自己的观测表征与历史读取它。允许集合不同的接收方需要各自构造全局表示。

2 方案一 数量解耦的全局注意力

2.1 科学问题

当红蓝数量变化时，策略需要同时处理两种变化。第一种是任务的实际负载发生变化，第二种是实体数量改变了注意力归一化的结果。二者在普通全局注意力中相互混合。

设智能体查询为 q_i ，实体键和值为 k_j, v_j 。普通注意力为

$$s_{ij} = q_i^\top k_j / \sqrt{d}, \quad \alpha_{ij} = \frac{\exp(s_{ij})}{\sum_k \exp(s_{ik})}.$$

当各实体得分近似相同时，一类实体获得的总注意力近似正比于该类数量。固定数量的目标可能随红蓝人数增加而获得更小的权重。另一方面，在固定查询和逐实体键值编码下，整体复制全部键值会使普通注意力输出保持不变，表明它也不能可靠保存绝对数量。已有 cardinality-preserved attention 工作分析了后一类不可辨识问题。[注意力与集合基数研究](#)

本方案检验的假设是，分离实体内容与实体数量的作用，可以减轻规模变化造成的表示偏移，使策略通过显式数量条件学习任务负载的变化。

2.2 新增分支的前向计算

原逐实体编码 $e_j = \text{ReLU}(W_e x_j + b_e)$ 同时供原路径与新增全局分支使用；它不含其他实体的信息，因此可共享这一步计算。原输入是否包含上一动作等字段，完全沿用基线信息协议，不因新增分支扩大可见字段。新增分支用自身编码和上一环境步记忆构造查询 $q_i = W_q[e_i, h_{i,t-1}]$ ，用允许实体生成键和值 $k_j = W_k e_j$ 、 $v_j = W_v e_j$ 。新增注意力的每个头执行

$$s_{ij} = q_i^\top k_j / \sqrt{d_k}, \quad \tilde{s}_{ij} = s_{ij} - \log n_{c_j}, \quad j \in S_i,$$

$$\tilde{\alpha}_{ij} = \frac{\exp(s_{ij})/n_{c_j}}{\sum_{k \in S_i} \exp(s_{ik})/n_{c_k}}, \quad u_i^{[h]} = \sum_{j \in S_i} \tilde{\alpha}_{ij}^{[h]} v_j^{[h]}, \quad u_i = W_O \text{Concat}_h(u_i^{[h]}).$$

上式 $[h]$ 表示注意力头，得分与归一化在各头分别计算，再拼接并作输出投影。空类没有对应的实体项，因此不计算 $\log 0$ ；若整个允许键集合为空，将上下文定义为零向量。自身查询通道沿用 REFIL 的允许方式，不因此把被遮挡的实体重新放入键值集合。

方案一 | 数量解耦的全局注意力




图1 原实体注意力路径完整保留；数量校正仅作用于新增全局注意力。全局上下文与数量编码经橙色残差融合进入原 GRU。下方蓝色 Mixer 与损失仅用于训练。

校正的作用可用等得分情形说明。若有 20 个红方、20 个蓝方和 2 个目标，普通注意力分给目标类的总权重为 $2/42$ ；校正后，三类总权重各为 $1/3$ 。实际得分不等时，三类不必等权，内容仍影响选择。这只是算子示例，不表示目标在真实任务中应固定占三分之一权重。

固定查询与键值后，将某一类的全部实体复制 m 次，各副本权重中的 $1/n_c$ 同时缩小，合计贡献保持不变。**该性质仅适用于新增内容聚合算子**。原 REFIL 路径、历史状态和数量条件仍可能随人数改变，不能据此声称整个策略具有复制不变性。最终策略应当有能力根据真实数量改变行为。

2.3 如何训练与如何验证

本方案每个环境步只计算一次新增全局注意力，随后执行一次原时间 GRU。红蓝与目标数量从允许实体直接计数，有界函数固定不训练；数量编码器、注意力投影、融合投影及原 REFIL 参数共同学习。不提供“应该关注哪个目标”的标签，不增加注意力监督损失。

主、组内、组外三条训练分支使用相同参数，但各自根据掩码计算 n_c, z_n, u_i ，通过第 5 节的 REFIL 损失更新。数量校正项本身是确定性运算，梯度通过校正后的 softmax 传向注意力参数。

对照	原路径	新增全局分支	数量输入	回答的问题
A0	保留	无	无	原 REFIL 参照
A1	保留	普通注意力	相同 z_n	增加全局分支与数量输入的基础收益
A2	保留	数量校正注意力	相同 z_n	数量校正本身是否有效

A1 与 A2 使用相同宽度、初始化规则、训练预算和执行信息，核心差别只有 $-\log n_c$ 。如果 A2 仅优于 A0，不能区分收益来自新增参数、数量输入还是校正；A2 相对 A1 的提升才直接支持核心机制。

先在固定键值的复制诊断中检验算子性质，再在真实环境中冻结评估人数、红蓝比例及目标数变化。固定目标类权重的变化可作为机制观察，团队收益才是有效性依据。复制键值不构成真实轨迹，不生成伪奖励。

2.4 科研潜力与边界

PAPO 已经研究人数条件化，CPA 已经研究注意力中的数量信息。因此，本方案的潜在贡献应定位为规模变化下内容读取与任务负载的解耦，以及对应的算子性质和跨规模验证。[PAPO](#)

这是三个方案中改动最小、机制最容易解释的一条，但独立论文的新颖性风险也最高。它不能恢复同一类别中已经被压缩掉的空间细节，也可能削弱某些任务中有用的数量权重。只有实际证明该偏移是当前外推失败的重要原因，才值得作为主要方法。

3 方案二 多深度全局循环表征

3.1 科学问题

全场可见并不意味着单次聚合已经形成了有用的协作表征。规模增加后，一次读取需要同时处理更多实体及其相互关系，而固定深度的网络未必能完成相同质量的信息整合。

本方案检验的假设是，共享的全局更新规则可以在小规模任务中学到可复用的交互处理过程，而不同智能体能够从不同计算深度中读取有用信息。

Perceiver 提供潜在槽反复读取原始输入的结构依据，Universal Transformer 提供沿计算深度共享参数的依据，Jumping Knowledge 提供按节点融合不同深度表征的依据。这些组件均已先例。[Perceiver](#)、[Universal Transformers](#)、[Jumping Knowledge](#)

3.2 新增全局循环的具体计算

全局工作空间包含 K 个 d 维槽。 K 是每轮的表示容量， R 是共享更新模块的调用次数。第一版固定 $K = 8$ ；这不是由人数确定的分组数量，槽也不预先对应目标或地理区域。

每个环境步从同一组可学习初始槽开始， $H_t^{(0)} = H_0$ 。初始槽不承接上一环境步的最终槽；跨环境时间的记忆由原 GRU 保存。为使数量参与全局计算，在每轮的槽查询中注入数量编码，定义

$$\begin{aligned}
 C^{(r)} &= \text{LN}(H^{(r-1)}) + \mathbf{1}_K(W_c z_n)^\top, \\
 \bar{H}^{(r)} &= H^{(r-1)} + \text{CrossAttn}_\theta(C^{(r)}, E, E), \\
 \hat{H}^{(r)} &= \bar{H}^{(r)} + \text{SelfAttn}_\theta(\text{LN}(\bar{H}^{(r)})), \\
 H^{(r)} &= \hat{H}^{(r)} + \text{FFN}_\theta(\text{LN}(\hat{H}^{(r)})).
 \end{aligned}$$

这里 SelfAttn 以归一化后的槽同时作为查询、键和值。所有轮次复用同一套 CrossAttn、SelfAttn、FFN、归一化与数量投影参数；不同子模块之间不共享参数。实体编码 E 每个环境步计算一次，每轮重新读取其中允许的实体。本方案独立使用普通交叉注意力，不叠加方案一的数量校正。

随机辅助分组可能使某个接收方没有允许的实体键。此时规定 CrossAttn 的聚合输出为零，不对全遮挡得分执行 softmax；槽仍可学习初始值继续更新，不补入被遮挡场景的信息。

各智能体先用自己的原路径表征和上一环境步记忆形成查询 $v_i = W_v[\ell_i, h_{i,t-1}]$ ，分别读取每轮槽，再选择各轮的权重：

$$u_i^{(r)} = \text{Attn}_\phi(v_i, H^{(r)}, H^{(r)}),$$

$$\omega_i^{(r)} = \frac{\exp g_\phi(v_i, u_i^{(r)})}{\sum_{s=1}^R \exp g_\phi(v_i, u_i^{(s)})}, \quad u_i = \sum_{r=1}^R \omega_i^{(r)} u_i^{(r)}.$$

读取器和评分函数同样跨轮共享，不使用限制最大轮数的查表式深度嵌入。输出 u_i 经第 1.3 节的残差融合进入原 GRU。整个环境步只提交一次时间记忆更新。




图2 共享模块每轮重新读取实体，保存所有轮次的槽表示。每个智能体用自己的观测与历史选择槽和轮次，最终进入蓝色 GRU 与动作头。图中的循环发生在同一环境步内。

3.3 轮数如何确定，网络如何学会循环

本版不假设存在“正确循环轮数”标签。训练时从 $\{1, 2, 4\}$ 均匀采样计算深度，通过实际任务回报训练这些深度下的最终动作价值。更多轮数是否有用由验证结果回答，不预设循环越多越好。随机深度训练参考循环深度模型的思想，此处离散集合与强化学习结合方式属于本研究设计。[循环深度模型](#)

数据采集时，每局独立采样一个 R ，整局固定，所有人数都使用同样的深度分布。回放训练时，每个 minibatch 独立采样一个 R ，该批次各完整序列的主、组内、组外和目标网络均使用这个 R 。这是将上一版“每序列固定轮数”具体化为便于对齐的批次级采样。回放仍保存真实动作和奖励，训练时按当前深度重建隐藏状态；采用 REFIL 原有离策略 Q 学习，不复用数据采集时缓存的隐藏状态。

例如采样 $R = 4$ 时，当前时刻先得到 $H^{(1)}, H^{(2)}, H^{(3)}, H^{(4)}$ ，再融合各轮结果，计算一次 GRU 与 Q。仅对最终融合输出计算主／辅助价值损失，但早期轮次通过两条路径收到梯度：一条来自跨轮读取，另一条经后续循环更新反传。训练不截断这四轮之间的梯度，也不额外给每轮提供“层级语义”监督。

这与普通 RNN 的训练原则相同：将共享模块按调用次数展开，再进行反向传播。区别在于这里存在两条轴： t 是环境时间， r 是同一时刻的信息加工深度。时间 GRU 沿 t 展开；全局模块沿 r 展开。两条轴不能混用，四轮内部计算不代表环境前进了四步。

比较组	全局更新	读取方式	主要检验
B1	单轮， $R = 1$	单轮槽读取	新增槽结构的基础效果
B2	共享多轮	仅读最后一轮	反复更新是否有用
B3	共享多轮	个体跨轮读取	各智能体选择不同深度是否额外有用
B4	非共享多层	与 B3 相同的跨层读取	共享更新规则相对普通加深的作用

B2、B3 在相同 R 下比较；B4 使用相同模块结构、宽度和最大深度，按相同的前缀深度训练，报告其更多的参数量，不能同时宣称参数量也完全匹配。各组使用相同数量条件与原 REFIL 路径。

冻结后在所有规模分别测试 $R = 1, 2, 4$ ，其中 B1 仅执行其单轮结构。先固定同一个 R 比较训练规模与未见规模，检验人数外推；再固定同一个规模比较不同 R ，检验增加计算的作用。仅对共享循环模型额外测试 $R = 8$ ，作为超过训练深度的压力测试；B4 没有第 5 至第 8 层的独立参数，不能直接这样扩展。若需要选一个部署轮数，在预先划定的小规模验证集选择，不能看过最终 20／50 人测试结果再选。

当前自适应性体现为实体读取与跨轮加权，尚不包括提前停止。只有 B3 在相同深度下优于 B2，并且干预某轮表征影响真实团队收益，才支持“不同智能体需要不同加工深度”这一假设。循环轮次本身不等于明确的个体层、小组层和战略层。

3.4 科研潜力与边界

这条路线最贴近当前核心想法，适合作为优先验证的主线。论文需要证明可复用计算深度与个体按需读取对规模外推的作用。MARIE 已在多智能体世界模型中使用 Perceiver 聚合，因此仅将潜在槽移植到 MARL 不能作为充分的新颖点。[MARIE](#)

固定 K 可能限制容量，多轮更新也可能重复信息或造成表征趋同。跨轮注意力选择的是已经计算出的结果，不会自动减少计算轮数。第一版只验证深度的有效性，不引入自适应停止器。

4 方案三 决策反馈的循环全局协调

4.1 方案三究竟增加了什么

方案二的循环只反复处理环境实体：场景进入全局模块，产生多轮表征，智能体读取后再决定动作。方案三增加的是一条**暂定决策反馈路径**：先产生一版动作偏好，将这些偏好送回全局模块，再产生下一版动作偏好，最后一轮才真正执行。

以三个智能体和 A、B 两个目标为例，假设动作允许选择目标。下面数值仅用于解释计算关系，不是实验结果，也不是算法要求的分配规则。

智能体	第一轮偏向 A	第一轮偏向 B
1	0.8	0.2
2	0.7	0.3
3	0.6	0.4

第一轮三个智能体都更偏向 A。方案三将这些暂定偏好与实体信息一起用于第二轮，使网络有机会识别“大家可能同时去 A”，并结合位置和局势重新计算。它不会规定必须有人去 B；只有这种调整有利于团队回报时，价值学习才有理由支持它。若三者同时改变偏好，也可能产生新的冲突，因此反馈不保证收敛。

机制	方案二	方案三
循环输入	场景、数量、上一轮槽	以上信息，加其他智能体的暂定动作偏好
循环期间是否计算候选 Q	无需，最终融合后计算	每轮都计算候选 Q
试图修正的对象	全局表征	全局表征与准备采取的行动
是否需要知道别人的内部决策结果	不需要	原设计需要

这也暴露了上一版需要补充的信息前提：**看到全场实体，不等于知道其他智能体的暂定动作偏好**。如果其他智能体使用了各自的私人历史，其偏好通常需要通信、中央执行模块，或足以重建全部内部计算的公共完整历史。若任务要求智能体之间不通信，并且不具备后两种条件，原方案三不能直接使用。改成每个智能体在本地预测他人的偏好属于另一项建模假设，需要重新定义和验证。

因此，当前建议先验证方案一、二；方案三作为扩展机制保留，不把获取他人偏好视为无成本的输入。

4.2 科学问题

即使多个智能体都正确理解了全局态势，它们仍可能同时选择相同目标，或同时作出相同的支援调整。此时需要处理的不仅是环境状态，还包括其他智能体在当前状态下准备采取的动作。

本方案检验的假设是，**让暂定决策参与下一轮全局更新，可以将循环计算用于修正协作关系，从而缓解人数增加后的重复投入与协调冲突**。

TarMAC 已研究执行前的多轮通信，VPP 通过策略传播协调联合行为，R2G 显式考虑其他智能体的潜在响应。因此，决策反馈与递归推理本身均非空白。[TarMAC](#)、[VPP](#)、[R2G](#)

4.3 方法（满足执行信息前提时）

采用与方案二相同的实体编码、槽容量、共享更新框架和个体读取接口。第一轮根据当前场景生成初始动作效用，随后将各红方智能体的暂定动作偏好重新送入全局模块。

第 r 轮的偏好定义为

$$p_i^{(r)}(a) = \text{softmax}_a \left(Q_i^{(r)}(a) / \tau \right),$$

其中 τ 是固定的平滑温度，第一版取 1，非法动作不参与归一化。 $p_i^{(r)}$ 仅表示由效用构造的暂定动作偏好，不解释为经过校准的成功概率，也不以此替代 REFIL 的最终动作选择。

记 $P^{(r)}$ 为这些偏好及其所属实体信息的集合。第二轮开始执行

$$H^{(r)} = F_{\theta} \left(H^{(r-1)}, E, P^{(r-1)}, z_n \right), \quad r \geq 2.$$

个体读取截至第 r 轮的全部全局表征，按方案二的跨轮读取计算候选效用 $Q_i^{(r)}$ ，再形成 $P^{(r)}$ 。第一轮的决定反馈输入为空，所有轮次均使用相同参数。最后一轮输出用于实际执行。

动作集合固定时，消息可直接包含动作偏好向量。若动作对应可变数量的目标实体，则使用

$$b_i^{(r)} = \sum_{a \in \mathcal{A}_i} p_i^{(r)}(a) \varphi(x_i, a)$$

构造固定维消息，其中 φ 编码动作类型及其对应实体，避免将人数变化绑定到固定长度的动作索引。

03 决策反馈的循环全局协调

在同一环境步内修正暂定决策，最后一轮才执行动作




图3 决策反馈的循环全局协调。暂定动作偏好进入下一轮更新，仅最后一轮执行动作并写入时间记忆。

例如，第一轮可能使多个智能体都偏向目标 A。后续全局更新能够读取这一偏好分布，并使具有不同位置、任务处境智能体作出不同调整。此处只定义允许网络学习的反馈关系，不预先规定谁应该转向目标 B。

局部观测编码在同一环境步内保持固定。每轮使用同一个上一时刻记忆计算候选隐状态

$$\hat{h}_{i,t}^{(r)} = \text{GRU} \left(\ell_{i,t} + W_u u_{i,t}^{(r)} + W_n z_n, h_{i,t-1} \right),$$

并仅将最后一轮的候选写入 $h_{i,t}$ 。内部推演不会被当作多个环境时间步。

4.4 训练与关键验证

训练沿用随机 1、2、4 轮与 REFIL 价值目标，梯度通过暂定偏好和全局更新传播。第一版不训练世界模型，不增加模仿标签、显式协调奖励或收敛损失。数量解耦归一化不与本方案叠加，以便独立判断决策反馈的作用。

最关键的对照是在完全相同的循环框架中，分别使用空反馈、始终固定为第一轮的首选，以及每轮更新的首选。各组执行相同轮数，保持消息接口宽度一致。空反馈检验偏好信息是否有效，固定反馈与动态反馈的比较检验持续修正是否有效。

支持证据是动态反馈在相同计算预算下优于空反馈和固定反馈，并改善与任务收益相关的重复投入、碰撞或覆盖不足。可在固定场景下干预反馈消息，再进行配对环境续行，检验决策变化是否确实有利。偏好更分散、动作更多样都不能单独作为成功标准。

4.5 科研潜力与边界

这条路线比反复编码静态场景更明确地定义了循环的工作内容，尤其适合验证当前关注的协作趋同问题。潜在贡献是共享的全局决策修正规则能否在更大规模中继续发挥作用，而不是笼统提出一种通信机制。

主要风险是同步修正导致反复摇摆，以及完全对称的输入无法被确定性的共享策略自动打破。既有 R2G 也报告了某些协调结构下的局限，不能把递归推理直接等同于收敛或最优协调。[R2G，附录 D](#)

5 完整训练协议：方案一、二如何接入 REFIL

5.1 训练哪些参数，使用什么数据

两种方案都从随机初始化开始端到端训练，不先固定一个训练好的 REFIL 再单独训练新分支。原编码器、原注意力、fc2、GRU、Q 头、Mixer 与新增组件共同更新；目标网络包含它们的对应副本。若现有实验已规定其他初始化协议，各匹配对照共同沿用，不能只给新方法额外预训练。

回放存储原环境产生的完整 episodes，包括实体特征、观测及有效实体掩码、可行动作、实际动作、团队奖励和终止标记。训练规模、奖励与交互预算沿用相同实验协议。采集动作仍采用可行动作集合内的 ϵ -greedy；最终评估使用贪心动作。

5.2 主、组内、组外三条前向计算

REFIL 的随机辅助分支不是额外运行两个子环境，而是在同一条真实轨迹上，对实体关系进行随机遮挡，得到组内和组外两种条件效用。它们共同重建完整团队回报。[REFIL 原论文](#)

每次从回放取出训练 episodes 后，按原 REFIL 规则为每条序列采样随机二分组：先采样 $p \sim U(0, 1)$ ，再对实体独立采样 Bernoulli(p) 组标签。该次前向展开中，分组对整条 episode 固定，再与各时刻的观测、有效实体掩码组合。同一条 episode 在后续训练中重新采样分组，不把组标签绑定到真实战术分组。

分支	原路径	新增全局计算	用途
主分支 main	原允许观测	主分支允许集合内计数和聚合	执行动作、计算主团队价值
组内分支 in	原组内掩码	组内允许集合内重新计算	提供辅助效用
组外分支 out	原组外掩码	组外允许集合内重新计算	提供辅助效用

三条分支共享网络参数，但各自从零初始化时间记忆并沿 episode 独立展开。不能把主分支的 GRU 状态直接传给辅助分支，因为它已经编码了被遮挡的信息。[REFIL 辅助分支实现](#)

方案一按分支重新计算注意力校正和数量编码。方案二从共同的可学习常量 H_0 出发，在**每一轮**使用该接收方该分支的允许实体集合，不把先看过完整场景的槽拿来作最后一层遮挡。逐实体 fc1 编码可复用；已经整合上下文的槽、个体历史和全局摘要不能跨不相同的允许集合复用。具体自身查询例外沿用原 REFIL，不扩大键值信息权限。

主分支各智能体对回放实际动作的效用经原 Mixer 得到 Q_{tot} ；组内、组外效用拼接为 $2N_A$ 个因子，按原 imagined 接口共同进入同一个参数共享 Mixer，得到 Q_{aux} ，其中 N_A 是决策智能体数。不是分别为两个子群指定奖励，也不在组内、组外独立选择另一套联合动作。原 Mixer 仍是集中训练组件，保留原全局状态条件及辅助混合方式；上述策略信息限制不意味着要求 Mixer 只能读取局部观测。[REFIL Mixer](#)

5.3 TD 目标与唯一训练损失

设本批次深度为 R ；方案一恒取 $R = 1$ 。在线主分支先在下一时刻的可行动作中选取

$$a_{i,t+1}^* = \arg \max_{a \in \mathcal{A}_{i,t+1}} Q_{i,R}^{\text{main}}(\tau_{i,t+1}, a).$$

目标网络主分支用同样的深度评价这些动作，得到 Double-Q 目标

$$y_{t,R} = r_t + \gamma(1 - d_t)Q_{\text{tot},R}^-(\tau_{t+1}, \mathbf{a}_{t+1}^*).$$

d_t 沿用当前环境对真实终止与时间限制的处理。目标整体停止梯度；辅助分支使用同一个 $y_{t,R}$ ，不另外计算辅助 TD 目标。设 m_t 为有效训练位置掩码，则

$$\mathcal{L}_R = \frac{1}{\sum_t m_t} \sum_t m_t [(1 - \lambda)(Q_{\text{tot},R,t} - y_{t,R})^2 + \lambda(Q_{\text{aux},R,t} - y_{t,R})^2],$$

$$\mathcal{L} = \mathbb{E}_R[\mathcal{L}_R].$$

公式中的求和包括批次内各 episode 的有效时刻，排除 padding 和终止后的无效位置。参数更新沿用 REFIL 的价值训练，新增模块不使用层次标签、注意力标签、蒸馏目标或额外奖励。[REFIL 训练实现](#)

5.4 一次优化更新的顺序

1. 从回放取一批完整 episodes，采样各自的随机分组，初始化三个分支的时间记忆。
2. 方案一设 $R = 1$ ；方案二为本批次采样 $R \in \{1, 2, 4\}$ ，所有分支和目标计算保持一致。
3. 沿环境时间重建主、组内、组外 Q；每个时刻按对应掩码重算新增分支，方案二完整展开 R 轮，之后更新一次 GRU。
4. 对三分支 Q 取出回放实际动作对应的效用，交给原 Mixer 得到主与辅助团队价值。
5. 用在线主分支选择下一动作，用无梯度目标主分支计算同一个 TD 目标，形成上述加权损失。
6. 通过环境时间与内部循环反向传播，裁剪梯度，执行一次优化器更新；按既定周期同步目标网络全部参数。

这一步只进行一次优化器更新，不是每个循环轮次更新一次参数。随机分组和循环深度在一次展开中保持固定，避免同一训练序列的历史定义不断改变。

部署时仅运行主分支，移除随机分组、辅助分支与 Mixer。方案一单次读取后执行动作；方案二按选定轮数完成全局加工后执行动作，时间 GRU 都是每个环境步更新一次。

5.5 首轮可采用的具体设置

现有已冻结实验协议优先。下表左列标明来源，避免把作者默认值或建议起点误写为已经验证的最佳超参数。

来源	项目	起点或处理方式
REFIL 作者配置	实体／注意力维度、头数	128 维、4 头
REFIL 作者配置	GRU 隐状态	64 维
REFIL 作者配置	辅助损失权重 λ	0.5
REFIL 作者配置	优化器	RMSprop，学习率 5×10^{-4} ， $\alpha = 0.99$ ， $\epsilon = 10^{-5}$
REFIL 作者配置	折扣、梯度裁剪	$\gamma = 0.99$ ，梯度范数上限 10
REFIL 作者配置	批次、回放容量	32 条完整 episodes、5000 条 episodes
REFIL 作者配置	目标网络	每 200 个采集 episodes 硬更新，沿用作者计数方式
REFIL 作者配置	探索	ϵ 从 1 到 0.05，500000 环境步退火
本研究建议	数量编码 z_n	6→32→32 的两层 MLP，中间使用 ReLU；两方案及匹配对照一致
本研究建议	新增全局注意力／槽维度	沿用 128 维、4 头；前馈中间维度取 $4d$
本研究建议	方案二的槽与深度	$K = 8$ ；采集按局、训练按批次均匀采样 $R \in \{1, 2, 4\}$
本研究建议	停止机制与额外目标	首版不加入

作者参数依据 [refil.yaml](#) 与 [default.yaml](#)。若现有基线使用不同宽度、预算或优化参数，所有新方法 与匹配对照共同沿用该基线设置，不单独为新方法扩大训练资源。

6 最小研究验证与推进顺序

研究方案与当前已经冻结的实验排期分开处理。已有 v3 结果只在信息权限、训练预算和评估协议一致时复用。本轮优先比较方案一、二；方案三只有在明确满足其执行信息前提后才进入实验。

方案	唯一核心变化	必要的匹配对照	论文必须取得的证据
一 数量解耦	全局注意力的数量归一化	同样数量输入与结构的普通注意力	表示性质成立，并带来真实规模外推收益

方案	唯一核心变化	必要的匹配对照	论文必须取得的证据
二 多深度表征	共享更新与个体跨轮读取	单轮、最后一轮读取、相近计算量的非共享深层网络	迭代有效，且个体选择计算深度有额外收益
三 决策反馈	将暂定动作偏好送入后续更新	执行信息前提相同，循环中的空反馈和固定反馈	动态反馈在相同预算下改善真实协作

训练规模、环境奖励和主要 D / NDS 指标沿用现有协议。在较大规模上冻结评估，并分别报告人数扩大、红蓝比例变化和目标数变化，避免将这些不同变化合并为一个平均分。以前讨论的 2-10 训练、20 与 50 测试为例，各模型均须在相同测试规模比较相同循环预算。

模型选择只使用预先划定的验证集合。最终大规模测试不能反复用于调参。单种子可筛选明显无效的结构，论文结论需要独立训练种子支持。循环方法同时报告参数量、计算量或推理耗时及环境交互预算；环境步数相同并不意味着计算成本相同。

优先推进方案二，它最直接回答当前提出的全局多轮处理与个体选择性读取问题。若允许获取其他智能体的暂定偏好，且重复决策仍是主要失效原因，再考虑方案三。方案一适合先做成本较低的机制诊断；若数量归一化偏移对任务没有实质影响，就不继续将其扩展为主方法。

最有潜力的论文问题表述为：**在有限训练规模下，能否学习一个可复用的全局信息更新规则，使智能体在更大规模中通过增加有效计算或利用决策反馈，维持协作决策质量。**